Penanganan *Cold Start* Film Menggunakan *Content Based Filtering* dan *Singular Value Decomposition*

Proposal Tugas Akhir

Kelas MK Penulisan Proposal (CCH4A3)

1301213540

Gemayel Peramana Ginting

Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung

2025/2026

Lembar Persetujuan

Penanganan C*old Start* Film Menggunakan *Content Based Filtering* dan *Singular Value Decomposition*

Handling Movie Cold Start Using Content Based Filtering and Singular Value Decomposition

NIM :1301213540

Gemayel Peramana Ginting

Proposal ini diajukan sebagai usulan pembuatan tugas akhir pada
Program Studi Sarjana Informatika
Fakultas Informatika Universitas Telkom

Bandung, 3 November 2025

Menyetujui

Calon Pembimbing 1

Dr. Z.K. Abdurahman Baizal, S.Si., M.Kom.

NIP. 99750047

Daftar isi

Lembar Persetujuan 1
ABSTRAK 3
1. PENDAHULUAN 4
1.1. Latar Belakang 4
1.2. Perumusan Masalah 6
1.3. Tujuan 6
1.4. Rencana Kegiatan 6
2. KAJIAN PUSTAKA 9
2.1. Penelitian Terkait 9
2.2. Sistem Rekomendasi 11
2.3. *Collaborative Filtering* 11
2.4. *Content-Based Filtering* 12
2.5. *Hybrid Filtering* 13
2.6. *Model-Based CF: Matrix Factorization* (SVD) 14
2.7. *Model-Based CF: Matrix Factorization* (SVD) 16
3. PERANCANGAN SISTEM 17
3.1 Arsitektur Sistem 17
3.2. Dataset 19
3.3. Data Preprocessing 21
3.4. Perancangan Sistem dan Model 22
3.5. Skenario Pengujian dan Evaluasi 23
3.6. Lingkungan Pengembangan 24
DAFTAR PUSTAKA 25

ABSTRAK

Kemajuan teknologi memunculkan beragam platform streaming film yang menyediakan puluhan ribu koleksi film. Namun, berlimpahnya pilihan seringkali membuat pengguna kesulitan dalam menentukan tontonan yang sesuai dengan selerea mereka, sehingga dibutuhkan sistem rekomendasi untuk membantu memilih film yang relevan. Pendekatan yang lazim digunakan adalah *Collaborative Filtering* (CF). Berbagai studi telah mengembangkan RS dengan metode seperti *item-based*, *user-based* CF, dan *Matrix Factorization* (MF). Akan tetapi, metode CF konvensional tersebut memiliki kekurangan mendasar, yakni *Data Sparsity* dan *Cold Start Problem* (CSP), dimana sistem tidak mampu memberikan rekomendasi kepada pengguna baru yang belum memiliki riwayat rating. Oleh karena itu, penelitian ini mengusulkan penerapan *Hybrid Filtering* dengan strategi *switching* praktis untuk mengatasi hambatan tersebut. Metode ini memanfaatkan kekuatan *Content-Based Filtering* (CBF) dalam menangani *cold start* pengguna dengan merekomendasikan berdasarkan genre yang dipilih pengguna. Di sisi lain, *Collaborative Filtering* berbasis *Matrix Factorization* (SVD) akan diterapkan untuk mengelola data *sparsity* pada pengguna yan sudah terdaftar. Penelitian ini akan memanfaatkan dataset public MovieLens. Evaluasi akan difokuskan pada pembuatan prototipe web yang berfungsi dan pengujian kualitatif (*User Acceptance Testing*) untuk menilai relevansi rekomendasi bagi pengguna baru. Penerapan pendekatan *hybrid switching* ini diharapkan dapat menghasilkan rekomendasi yang sesuai untuk pengguna baru dan memverifikasi solusi praktis terhadap masalah user *cold start*.

Kata Kunci: sistem rekomendasi, hybrid filtering, cold start, collaborative filtering, content-based filtering, film

1. PENDAHULUAN

1.1. Latar Belakang

Era digital telah memicu ledakan informasi (*information overload*) yang menuntut adanya penyarigan informasi yang efektif [8]. Hal ini sering membuat pengguna merasa kewalahan menghadapi volume informasi yang sangat besar dalam berbagai platform digital [11]. Dalam berbagai bidang, khususnya pada platform hiburan digital seperti layanan *streaming* film, pengguna dihadapkan pada ribuan pilihan konten [10]. Banyaknya pilihan ini menimbulkan kebingungan atau *consumer confusion* dalam menentukan tontonan yang sesuai dengan prefrensi mereka [4]. Kondisi ini menjadikan Sistem Rekomendasi bukan sekedar fitur tambahan, melainkan elemen bisnis penting untuk personalisasi konten pengguna [3]. Penererapan sistem rekomendasi yang efektif juga terbukti dapat meningkatkan retensi pengguna pada suatu platform [8].

Pendekatan umun yang digunakan adalah *Collaborative Filtering* (CF) [4]. Namun, beberapa penelitian menunjukkan bahwa metode CF murni ini memiliki kelemahan ketika dihadapkan pada kondisi data yang tidak ideal [1]. Beberapa masalah yang sering muncul adalah *Data Sparsity* yakni kondisi dimana matriks *user-item* memiliki terlalu banyak nilai kosong [2] dan *Cold Start Problem* (CSP), yaitu kesulitan sistem dalam memberikan rekomendasi bagi pengguna baru yang belum memiliki riwayat interaksi [8]. Masalah ini juga menjadi kendala utama ketika item baru diperkenalkan ke dalam sistem [10].

Permasalahan tersebut berdampak langsung pada penurunan akurasi dan kualitas rekomendasi, sehingga pengguna mengalami ketidakpuasan (*poor recommendations*) [2]. Ketidakpuasan ini dapat menyebabkan pengguna meninggalkan platform jika tidak ditanggani dengan baik [8]. Oleh karena itu untuk mengatasi keterbatasan tersebut, penelitian di bidang RS mulai beralih ke pendekatan *Hybrid Filtering* yang menggabungkan beberapa metode rekomendasi [6]. Pendekatan ini juga memungkinkan berbagai sumber data yang terintegrasi untuk menghasilkan akurasi yang lebih tinggi dibanding metode tunggal [3]. Selain itu, pendekatan hybrid juga terbukti lebih efektif dalam menangani scenario yang kompleks diabnding metode konvensial [13].

Penelitian ini akan menggunakan Teknik *Model-Based Collaborative Filtering*, khususnya *Matrix Factorization* (MF). Sebagaimana dijelaskan oleh Wang (2022) [7], yaitu bahwa MF khususnya varain *Singular Value Decomposition* (SVD) lebih unggul dalam menangani *data sparsity.* Studi terbaru dari Rini et al. (2025) [12] juga menunjukkan bahwa *Singular Value Decomposition* (SVD), salah satu varian MF, memberikan hasil prediksi yang lebih akurat (nilai MAE/RMSE lebih rendah) dibandingkan metode *neighborhood-based* seperti KNN. Pendekatan serupa juga diadopsi oleh Patro et al. (2020) [1] melalui penggunaan mekanisme *Hybrid* pada dataset MovieLens untuk mengatasi masalah sparsity.

Meskipun demikian, metode MF/SVD murni masih menghadapi tantangan pada kasus *user cold start*, karena model ini membutuhkan data interaksi awal untuk membangun representasi penggunua yang akurat [9]. Di sisi lain, berbagai solusi *hybrid* modern yang diusulkan dalam penelitian terkini justru memiliki kompleksitas tinggi dan memerlukan sumber daya komputasi besar seperti arsitektur *SCSHRS* (HOSVD + ANFIS) dan *MGRS-HFA* (Graph Neural Network-based Hybrid Filtering) [13]. Berdasarkan hal tersebut, terdapat celah penelitian (*research gap*) untuk mengembangkan sistem *hybrid recommender* yang bersifat lebih sederhana, namun tetap efektif dalam menangani permasalahan utama, yaitu *cold start* pada pengguna baru.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk merancang dan membangun sistem rekomendasi *Hybrid Filtering* dengan mekanisme *Switching* yang adaptif. Pendekatan ini dirancang untuk mengatasi masalah utama secara simultan yaitu *cold start* pada pengguna baru dengan memanfaatkan *Content-Based Filtering* berbasis genre film [10], [11], dan menangani masalah *data sparsity* pada pengguna terdaftar menggunakan Singular Value Decomposition (SVD) [7], [12]. Dengan pendekatan ini, diharapkan sistem dapat memberikan rekomendasi yang relevan sejak interaksi pertama pengguna sekaligus menjaga akurasi yang tinggi saat data interaksi mulai terbentuk seiring waktu [9].

1.2. Perumusan Masalah

Berdasarkan uraian pada bagian latar belakang, permasalahan utama yang diidentifikasi dalam penelitian ini adalah keterbatasan metode *Collaborative Filtering* (CF) murni, terutama pada isu *data sparsity* dan *cold problem* (CSP). Berdasarkan hal tersebut, rumusan masalah yang akan dijawab melalui penelitian ini adalah sebagai berikut:

1. Bagaimana penerapan CBF berbasis genre film dapat memberikan rekomendasi awal yang relevan untuk mengatasi permasalahan *cold start* pada pengguna baru?
2. Bagaimana efektivitas penerapan metode SVD dalam arsitektur *hybrid* dapat membantu mengurangi permasalahan *data sparsity* dan meningkatkan akurasi pada pengguna yang telah memiliki histori interaksi?
3. Bagaimana mengintegrasikan metode CBF dan SVD dalam arsitektur *hybrid* dengan mekanisme *switching* yang mampu memilih metode rekomendasi yang tepat?

1.3. Tujuan

Berdasarkan rumusan masalah yang telah dijelaskan sebelumnya, maka tujuan dari tugas akhir ini adalah sebagai berikut:

1. Menerapkan metode *Content-Based Filtering (CBF)* berbasis genre film untuk menghasilkan rekomendasi awal yang relevan, sebagai solusi terhadap permasalahan *cold start* pada pengguna baru.
2. Menerapkan metode *Model-Based Collaborative Filtering* dengan pendekatan *Matrix Factorization (SVD)* untuk mengatasi permasalahan *data sparsity* pada pengguna yang telah memiliki histori interaksi.
3. Mengimplementasikan arsitektur *Hybrid Switching* ke dalam sistem rekomendasi berbasis web yang divalidasi melalui pengujian akurasi (*RMSE/MAE*) dan evaluasi pengguna (*User Acceptance Testing*).

1.4. Rencana Kegiatan

Pengerjaan tugas akhir ini dilaksanakan melalui serangkaian tahapan yang

dirancang secara terstruktur dan sistematis guna mencapai tujuan penelitian yang telah ditetapkan. Adapun tahapan pelaksanaan tugas akhir ini adalah sebagai berikut:

1. **Studi Literatur**

   Tahap ini mencakup penelusuran dan kajian terhadap berbagai sumber ilmiah seperti jurnal dan artikel penelitian yang relevan.

2. **Pengumpulan Data**

   Data yang digunakan bersifat kuantitatif dan diambil dari dataset publik *MovieLens*. Dataset ini dipilih karena relevan dengan domain film dan memiliki struktur data yang lengkap.

3. **Perancangan Penelitian dan Implementasi Sistem**

   Tahap ini terdiri dari dua bagian utama:

   - **Perancangan Sistem:** Merancang arsitektur **Hybrid Filtering** dengan metode *switching*. Ini termasuk merancang alur *use case* untuk: (a) **Pengguna Baru (Cold Start)**, yang akan melalui alur *Content-Based Filtering* (CBF) dengan memilih genre favorit, dan (b) **Pengguna Terdaftar**, yang akan masuk ke alur *Collaborative Filtering* (CF) berbasis SVD.
   - **Implementasi Sistem:** Prototipe sistem akan dikembangkan menggunakan bahasa pemrograman **Python** dengan framework **Flask** (atau Django). Implementasi model SVD akan memanfaatkan pustaka seperti *Surprise* atau *scikit-learn*, sedangkan implementasi CBF berbasis genre akan menggunakan *pandas* untuk manipulasi dan analisis data.

4. **Pengujian dan Analisis Hasil**

   Tahap ini bertujuan untuk mengevaluasi kinerja dan efektivitas sistem yang dikembangkan. Pengujian dilakukan secara **kualitatif** melalui *User Acceptance Testing (UAT)* untuk menilai relevansi rekomendasi bagi pengguna baru (*cold start*), dengan melibatkan skenario pendaftaran, pemilihan genre, dan penilaian hasil rekomendasi.

   Selain itu, dilakukan **pengujian kuantitatif** menggunakan metrik **Mean Absolute Error (MAE)** dan **Root Mean Square Error (RMSE)** pada

model *Matrix Factorization (SVD)* untuk mengukur akurasi rekomendasi pada pengguna terdaftar dan menguji kemampuan sistem dalam menangani *data sparsity*.

5. **Penulisan Laporan**

   Tahap akhir berupa penyusunan laporan tugas akhir yang dilakukan secara bertahap dan berkesinambungan sesuai perkembangan penelitian dan hasil implementasi.

1.6. Jadwal Kegiatan

Berdasarkan rencana kegiatan yang telah disusun, Tabel 1 menyajikan detail jadwal pelaksanaan dari setiap tahapan yang direncanakan.

Kegiatan	**Bulan**					
Studi Literatur	1	2	3	4	5	6
Pengumpulan Data						
Implementasi Sistem						
Pengujian dan Analisis						
Penulisan Laporan						

Tabel 1 Jadwal kegiatan tugas akhir

2. KAJIAN PUSTAKA

2.1. Penelitian Terkait

Perkembangan dalam sistem rekomendasi saat ini berkembang dari penggunaan satu pendekatan menuju *Hybrid Filtering* untuk mengatasi keterbatasan algoritma tradisional. Kolli et al. (2024) [10] menegaskan bahwa integrasi berbagai Teknik diperlukan untuk menghadapi keragaman data pada platform modern. Hal ini selaras dengan hasil Patro et al. (2020) [1] yang menyatakan bahwa metode *hybrid* dapat mengkompensasi kekurangan informasi pada *Collaborative Filtering* (CF) atau *Content-Based Filtering* (CBF) saat digunakan secara terpisah. Bukti empiris menunjukkan bahwa penggabungan keduanya menghasilkan prediksi yang lebih tepat daripada metode individual, serta memberikan rekomendasi yang lebih stabil [3]. Dalam penelitian lain, terbukti bahwa sistem *hybrid* memberikan saran yang lebih stabil dan sesuai dibandingkan algoritma tunggal di bidang Pendidikan dan hiburan. Lebih lanjut, Xu et al. (2025) [9] menambahkan bahwa integrasi teknik SVD dalam kerangka hybrid CF–CBF juga dapat menurunkan nilai RMSE secara signifikan pada data film.

Dalam masalah *Data Sparsity*, *Matrix Factorization* (MF) menjadi solusi utama karena efektif mengurangi kekosongan pada matriks interaksi pengguna item [2]. Validasi eksperimental membuktikan bahwa *Singular Value Decomposition* (SVD), sebagai salah satu teknik MF, memberikan kesalahan yang lebih kecil dibandingkan pendekatan berbasis tetangga pada data yang jarang [7]. Keunggulan SVD juga divalidasi oleh penelitian dari Rini et al. (2025) [12] yang menunjukkan bahwa SVD memiliki skalabilitas yang lebih baik dalam menangani dataset besar.

Masalah *Cold Start*, khususnya pada pengguna baru, juga menjadi perhatian utama. Penggunaan data demografis atau konten diusulkan sebagai solusi utama agar sistem tetap bisa memberikan saran saat belum ada riwayat interaksi [8]. Saputra et al. (2024) [11] memperkuat temuan ini dengan menunjukkan bahwa informasi genre pada platform *streaming film* dapat menjadi dasar yang kuat untuk memprediksi preferensi awal pengguna. Pendekatan ini sejalan dengan temuan

Saaidin dan Kassim (2020) [5] yang memanfaatkan *genre* dan *topic modelling* untuk mengatasi ketiadaan rating awal.

Peneliti (Tahun)	**Metode Utama**	**Fokus Masalah**	**Kelebihan dan Kekurangan**
Patro et al. (2020) [1]	Hybrid (Bi-Clustering + information Gain)	Cold Start & Sparsity	(+) Akurasi tinggi (-) kompleksitas komputasi tinggi karena proses clustering bertingkat
Zawia et al. (2025) [13]	Meta-Learning	Cold Start	(+) Adaptif terhadap user baru (-) Membutuhkan resource besar dan arsitektur model sangat kompleks
Xu et al. (2025) [9]	Hybrid (SVD +CBF)	Rating Prediction	(+) Menggabungkan SVD dan konten (-) Fokus pada penurunan error prediksi, belum membahas mekanisme switching dinamis untuk implementasi web.
Penelitian ini (2025)	Hybrid Switching CBF + SVD	Cold Start & Sparsity	(+) Menggunakan mekanisme switching yang ringan dan adaptif untuk transisi dari user bar uke user lama.

Tabel 2 Perbandingan Penelitian Terkait

2.2. Sistem Rekomendasi

Sistem rekomendasi merupakan mekanisme penyaringan informasi yang memprediksi preferensi pengguna terhadap suatu *item* untuk membantu pengambilan keputusan [8]. Dalam perkembangannya, RS menjadi salah satu komponen penting dalam berbagai platform digital untuk mengatasi permasalahan *information overload* (ledakan informasi) [4], [11], yaitu kondisi ketika pengguna dihadapkan pada jumlah pilihan item yang sangat besar, seperti pada layanan rekomendasi film [10]. Dalam era keterjangkauan data yang sangat besar, sistem rekomendasi berperan penting dalam mengurangi *information overload* sehingga pengalaman pengguna tetap optimal [3]. Efektivitas rekomendasi sangat ditentukan oleh kemampuan sistem dalam melakukan personalisasi berbasis perilaku dan minat pengguna, baik yang diperoleh secara eksplisit maupun implisit [7].

2.3. *Collaborative Filtering*

Collaborative Filtering (CF) merupakan salah satu teknik penyaringan informasi yang paling populer dan banyak digunakan dalam sistem rekomendasi [4]. Konsep utamanya adalah memanfaatkan perilaku dan preferensi dari komunitas pengguna untuk memprediksi minat pengguna target, sehingga sistem dapat merekomendasikan item yang relevan bagi mereka [3]. CF bekerja berdasarkan data historis interaksi pengguna dan item yang direpresentasikan dalam sebuah matriks pengguna-item (*user–item matrix*) [2].

Secara umum, terdapat dua pendekatan utama dalam CF [4], [7]:

- **Pendekatan *Memory-Based*:** Pendekatan ini menggunakan keseluruhan data interaksi untuk menghitung kesamaan antar pengguna (*User-Based CF*) atau antar item (*Item-Based CF*). Nilai kesamaan biasanya dihitung dengan metrik statistik seperti *Pearson Correlation* atau *Cosine Similarity*. Namun, pendekatan ini memiliki kelemahan dalam hal skalabilitas ketika diterapkan pada dataset berukuran besar [12].
- **Pendekatan *Model-Based*:** Pendekatan ini memanfaatkan teknik *machine learning* untuk melakukan proses *training* terhadap data interaksi,

kemudian membangun model prediktif yang dapat menghasilkan rekomendasi baru tanpa perlu mengakses keseluruhan database. Pendekatan ini lebih *scalable* dan efektif dalam menangani masalah *data sparsity* [1], [6]. Model yang paling umum dan kuat dalam kategori ini adalah ***Matrix Factorization*** **(MF)** [7].

2.4. *Content-Based Filtering*

Content-Based Filtering (CBF) merupakan pendekatan dalam sistem rekomendasi yang menghasilkan rekomendasi berdasarkan tingkat kemiripan fitur atau konten antara item yang telah disukai pengguna sebelumnya dengan item lainnya [3], [11]. Proses kerja CBF umumnya melibatkan tiga tahapan utama, yaitu pembentukan *item profile*, *user profile*, dan proses *matching*.

Pada tahap *item profile*, sistem mengekstraksi berbagai fitur atau karakteristik dari setiap item untuk membangun representasi profil item. Dalam konteks rekomendasi film, fitur yang digunakan dapat berupa *genre*, sutradara, aktor, hingga *keywords* dari sinopsis film [5]. Selanjutnya, sistem membangun *user profile* dengan menganalisis fitur-fitur dari item yang telah disukai atau diberi rating tinggi oleh pengguna, sehingga terbentuk gambaran preferensi pengguna terhadap jenis konten tertentu. Setelah kedua profil terbentuk, sistem melakukan proses *matching*dengan membandingkan kesamaan antara profil pengguna dan profil item-item lain yang belum pernah dilihat pengguna. Perbandingan ini dilakukan menggunakan metrik kesamaan, seperti *Cosine Similarity*, untuk menentukan item yang memiliki tingkat kemiripan tertinggi dan layak direkomendasikan kepada pengguna. Kelebihan utama dari pendekatan CBF adalah kemampuannya dalam mengatasi sebagian permasalahan *Cold Start Problem*, khususnya pada item baru yang telah memiliki informasi konten lengkap [10].

Namun, metode ini juga memiliki keterbatasan berupa kecenderungan terhadap *over-specialization*, di mana sistem hanya merekomendasikan item yang sangat mirip dengan preferensi pengguna sebelumnya. Kondisi ini dapat menimbulkan fenomena *filter bubble*, yaitu situasi ketika pengguna terus-menerus

menerima rekomendasi yang seragam dan kehilangan kesempatan untuk menemukan item yang lebih beragam [6].

2.5. *Hybrid Filtering*

Hybrid Filtering adalah pendekatan yang mengintegrasikan dua atau lebih teknik rekomendasi untuk menciptakan sinergi, di mana keunggulan satu metode menutupi kelemahan metode lainnya [1]. Kolli et al. (2024) [10] menjelaskan bahwa hibridisasi adalah solusi paling efektif untuk mengatasi masalah fundamental seperti *Cold Start* dan *Data Sparsity* yang tidak dapat diselesaikan oleh metode tunggal. Bukti empiris dari Kannikaklang et al. (2022) [6] menunjukkan bahwa sistem *hybrid* secara konsisten menghasilkan metrik akurasi (Presisi, Recall) yang lebih tinggi dibandingkan CF atau CBF murni.

Terdapat berbagai strategi hibridisasi yang telah diterapkan dalam penelitian terkini:

1. **Weighted Hybrid:** Menggabungkan skor prediksi dari beberapa metode dengan bobot tertentu. Kannikaklang (2022) menerapkan *post-fusion* dengan pembobotan dinamis untuk meningkatkan presisi prediksi rating.
2. **Feature Augmentation:** Menggunakan output dari satu metode sebagai fitur input untuk metode lain. Xu et al. (2025) membuktikan bahwa integrase fitur laten SVD ke dalam model konten secara signifikan mengurangi error prediksi.
3. **Switching Hybrid:** Sistem beralih antar teknik rekomendasi berdasarkan kriteria heuristik tertentu. Strategi ini sebagai cara efektif untuk menangani transisi dari pengguna baru (*new user*) ke pengguna aktif [1]. Jika data interaksi belum mencukupi, sistem menggunakan metode berbasis konten; jika sudah cukup, sistem beralih ke metode kolaboratif.

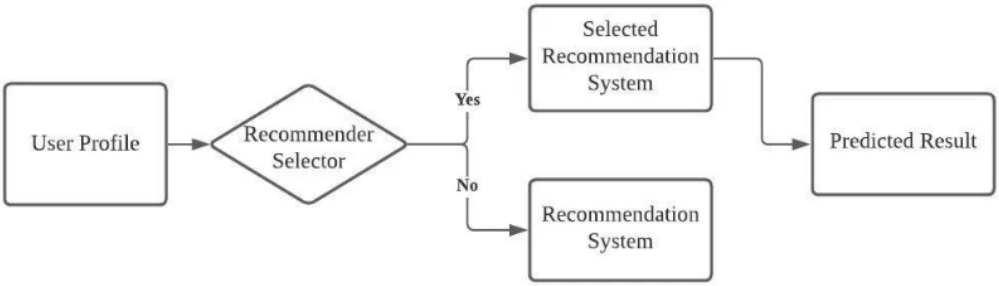

Gambar 1 Arsitektur *Hybrid Switching*

Alur kerja arsitektur *hybrid switching* pada Gambar 1 dimulai dari sistem yang menerima input berupa profil pengguna. Selanjutnya, terdapat komponen utama bernama *Recommender Selector* yang berfungsi sebagai blok pengambil keputusan. Komponen ini menentukan jalur pemrosesan berdasarkan status pengguna, yaitu apakah pengguna merupakan pengguna baru atau pengguna yang sudah memiliki riwayat interaksi. Jika pengguna terdeteksi sebagai pengguna baru (*cold start*), sistem akan mengarahkan proses ke modul *Content-Based Filtering (CBF)* untuk menghasilkan rekomendasi awal berdasarkan preferensi genre yang dipilih saat registrasi [11]. Sebaliknya, jika pengguna telah memiliki data interaksi sebelumnya, sistem akan menggunakan modul *Collaborative Filtering (CF)* berbasis *Matrix Factorization (SVD)* [7], [12] untuk memprediksi rating dan memberikan rekomendasi yang lebih akurat. Hasil akhir dari salah satu modul yang dipilih (CBF atau CF) kemudian ditampilkan kepada pengguna dalam bentuk daftar rekomendasi film yang sesuai dengan profil dan aktivitas mereka.

2.6. *Model-Based CF: Matrix Factorization* (SVD)

Penelitian ini menggunakan pendekatan *Model-Based Collaborative Filtering (CF)*, khususnya *Matrix Factorization (MF)*, sebagai bentuk penerapan *embedding* yang lebih canggih dibandingkan metode tradisional seperti TF-IDF. Seperti dijelaskan oleh Wang (2022) [7], *Matrix Factorization* dirancang untuk mengatasi permasalahan *Data Sparsity* dengan cara mempelajari serta memetakan pengguna dan item ke dalam ruang vector laten (*latent vector space*) berdimensi rendah.

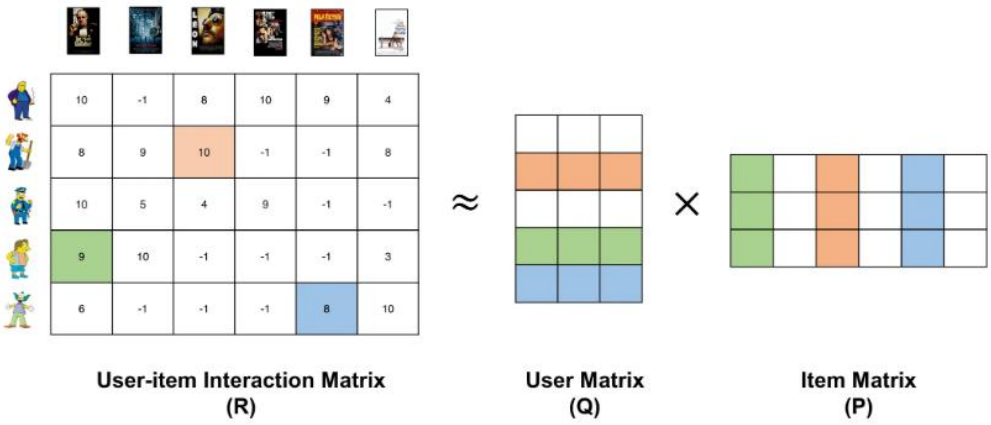

Gambar 2 Cara Kerja *Matrix Factorization*

Gambar 2 menunjukkan konsep dasar Matrix Factorization. *Matriks User-item Interaction* (R) yang besar dan *sparse* didekomposisi atau di-faktorisasi (≈) menjadi dua matriks berdimensi lebih kecil (disebut *latent factor matrices*):

1. **Matriks User (Q):** Berdimensi $m \times k$ (jumlah user × jumlah faktor laten).
2. **Matriks Item (P):** Berdimensi $k \times n$ (jumlah faktor laten × jumlah item).

k adalah jumlah *latent factors* yang dipilih. Prediksi *rating* $\hat{r}_{ui}$ untuk *user* u pada *item* i dihitung sebagai *dot product* dari vektor laten *user* q_u (baris ke-u dari matriks Q) dan vektor laten *item* p_i (kolom ke-i dari matriks P). Secara matematis, rumus prediksi ini ditulis sebagai:

$$\hat{r}_{ui} = q_u \cdot p_i = \sum_{k=1}^{k} q_{uk}\, p_{ki}$$

Salah satu algoritma paling populer dan efektif untuk melakukan *Matrix Factorization* adalah *Singular Value Decomposition* (SVD). Keunggulan SVD telah dibuktikan secara empiris oleh Rini et al. (2025) [12] membuktikan bahwa SVD secara signifikan lebih akurat (memiliki nilai MAE/RMSE lebih rendah) daripada metode *Memory-Based* (KNN). Keunggulan ini disebabkan karena SVD (sebagai *model-based*) jauh lebih baik dalam menggeneralisasi pola dari data *sparse* dan lebih *scalable* [9]. Penggunaan SVD-family (seperti HOSVD) untuk

menangani *sparsity* pada dataset MovieLens juga telah divalidasi oleh Patro et al. (2022) [1]

2.7. *Model-Based CF: Matrix Factorization* (SVD)

Cold Start Problem (CSP) merupakan salah satu tantangan utama dan mendasar dalam pengembangan Sistem Rekomendasi. Menurut Yuan dan Hernandez (2023) [8], CSP terjadi ketika sistem tidak mampu menghasilkan rekomendasi yang akurat akibat keterbatasan data interaksi antara pengguna dan item. Secara umum, CSP terbagi menjadi dua kategori utama [8]. Pertama**,** *Item Cold Start*, yaitu kondisi ketika item baru (misalnya film yang baru dirilis) masuk ke dalam sistem tanpa adanya rating dari pengguna. Akibatnya, pendekatan Collaborative Filtering (CF) tidak dapat memprediksi relevansi item tersebut [2]. Kedua, *User Cold Start*, yaitu ketika pengguna baru mendaftar dan belum memberikan rating terhadap item apa pun. Hal ini menyebabkan sistem CF, termasuk metode berbasis Matrix Factorization seperti SVD, tidak memiliki informasi yang cukup untuk mempelajari preferensi pengguna dan menghasilkan prediksi [2], [10].

3. PERANCANGAN SISTEM

3.1. Arsitektur Sistem

Penelitian ini terdiri dari beberapa tahapan utama. Tahapan-tahapan tersebut terdiri dari *Data Collection, Data Preprocessing, Hybrid Modeling,* dan *System Evaluation.* Gambar 3 memberikan gambaran lebih jelas mengenai alur penelitian yang akan dilakukan. Penelitian ini menerapkan arsitektur *Hybrid Filtering* dengan mekanisme *Switching*. Pemilihan metode ini didasarkan pada kemampuannya untuk menangani kondisi data yang dinamis: menggunakan CBF untuk mengatasi *Cold Start* dan SVD untuk menangani *Data Sparsity* dengan akurasi tinggi pada pengguna terdaftar.

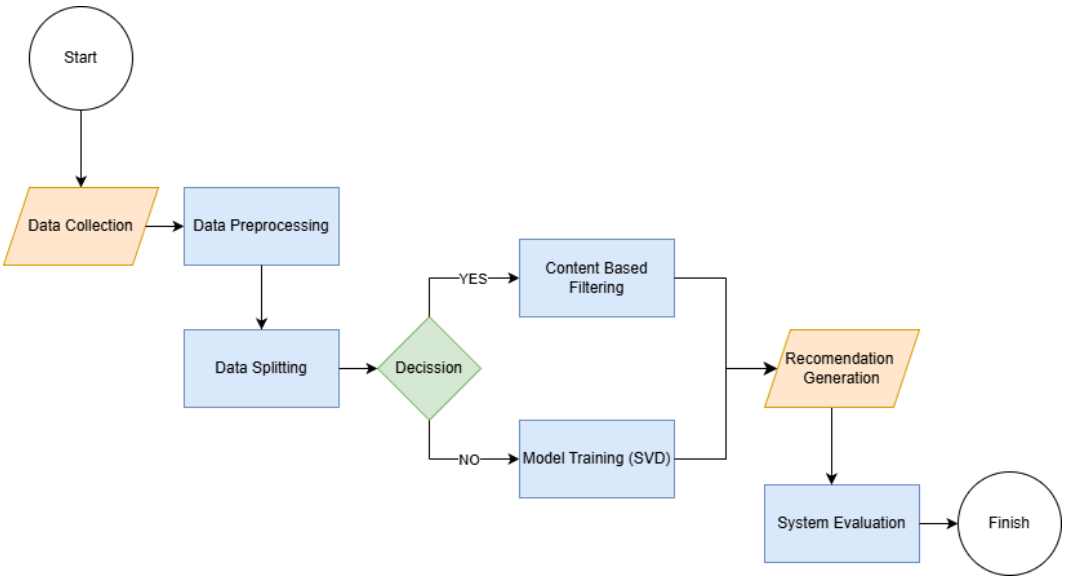

Gambar 3 Alur Kerja Sistem

Pada Gambar 3 penjelasan mendetail mengenai tahapan dalam diagram tersebut adalah sebagai berikut:

1. **Data Collection**

   Ini adalah tahap awal dimana sistem mengumpulkan bahan baku, aktivitas yang dilakukan disini adalah mengambil data dari database

atau sumber lain misalnya data rating film, data profil pengguna, atau data deskripsi produk.

2. **Data Pre-processing**

   Data mentah yang dikumpulkan biasanya masih "kotor" atau berantakan. Tahap ini bertujuan membersihkannya agar siap diolah, pada tahap ini akan dilakukan penghapusan data ganda (*duplicate*), mengisi data yang kosong (*missing values*), atau menyamakan format tulisan.

3. **Data Splitting**

   Pada tahap ini, Biasanya data dibagi menjadi **Data Latih (Training Data)** untuk mengajarkan sistem, dan **Data Uji (Testing Data)** untuk menguji seberapa pintar sistem nantinya. Rasio umumnya adalah 80:20 atau 70:30.

4. **Decision**

   Ini adalah gerbang dimana sistem mengecek kondisi tertentu untuk menentukan metode mana yang akan dipakai. Biasanya dalam sistem rekomendasi, ini digunakan untuk mengecek: *"Apakah pengguna ini pengguna baru yang belum punya riwayat rating?"* atau *"Apakah data cukup untuk menggunakan metode SVD?"*.

   - Jika **YES**: Masuk ke jalur atas (*Content Based*).
   - Jika **NO**: Masuk ke jalur bawah (*Model Training SVD*).

5. **Cabang Metode (Branch)**

   Di sini sistem memilih salah satu dari dua algoritma:

   - **Jalur Atas: Content Based Filtering**

     Sistem memberikan rekomendasi berdasarkan **kemiripan sifat barang**.

   - **Jalur Bawah: Model Training (SVD - Singular Value Decomposition)**

     Sistem memberikan rekomendasi berdasarkan **pola rating dari banyak pengguna lain** (*Collaborative Filtering*). SVD adalah teknik matematika untuk memprediksi rating yang kosong.

6. **Pembuatan Rekomendasi**

   Setelah salah satu metode di atas selesai bekerja, sistem akan menghasilkan daftar *output*, lalu Mengurutkan hasil prediksi dari nilai tertinggi ke terendah, lalu mengambil (misalnya) 5 atau 10 item teratas untuk ditampilkan ke pengguna.

7. **System Evaluation**

   Tahap ini mengukur seberapa akurat rekomendasi yang diberikan. Setelah itu Membandingkan hasil prediksi sistem dengan data asli menggunakan rumus statistik seperti *MAE (Mean Absolute Error)* atau *RMSE (Root Mean Square Error)*. Semakin kecil angkanya, semakin akurat sistemnya.

3.2. Dataset

Data yang digunakan dalam penelitian ini adalah dataset publik **MovieLens** yang disediakan oleh *GroupLens Research*. Dataset ini dipilih karena memiliki struktur yang mendukung penerapan metode *Hybrid Filtering*, yaitu tersedianya data interaksi pengguna (rating) untuk *Collaborative Filtering* dan data atribut film (judul dan genre) untuk *Content-Based Filtering*.

movieId	title	genres
1	Toy Story (1995)	Adventure|Animation|Children|Comedy|Fantasy
2	Jumanji (1995)	Adventure|Children|Fantasy
3	Grumpier Old Men (1995)	Comedy|Romance
4	Waiting to Exhale (1995)	Comedy|Drama|Romance
5	Father of the Bride Part II (1995)	Comedy
6	Heat (1995)	Action|Crime|Thriller
7	Sabrina (1995)	Comedy|Romance
8	Tom and Huck (1995)	Adventure|Children
9	Sudden Death (1995)	Action
10	GoldenEye (1995)	Action|Adventure|Thriller
11	American President, The (1995)	Comedy|Drama|Romance
12	Dracula: Dead and Loving It (1995)	Comedy|Horror
13	Balto (1995)	Adventure|Animation|Children
14	Nixon (1995)	Drama
15	Cutthroat Island (1995)	Action|Adventure|Romance
16	Casino (1995)	Crime|Drama
17	Sense and Sensibility (1995)	Drama|Romance
18	Four Rooms (1995)	Comedy
19	Ace Ventura: When Nature Calls (199	Comedy
20	Money Train (1995)	Action|Comedy|Crime|Drama|Thriller

Gambar 4 dataset film

Data film digunakan sebagai dasar untuk komponen *Content-Based Filtering*. Atribut utama yang dimanfaatkan adalah **Genre**. Dalam dataset ini, informasi genre direpresentasikan dalam format teks yang dipisahkan oleh delimiter (tanda pemisah). Atribut *genres* nantinya akan diproses menggunakan teknik *Text Processing* (seperti TF-IDF atau One-Hot Encoding) untuk menghitung tingkat kemiripan antar film (*Item Similarity*). Data rating merepresentasikan preferensi pengguna terhadap film tertentu. Data ini merupakan komponen utama untuk perhitungan *Collaborative Filtering* dan pembentukan matriks *User-Item*. Kombinasi antara userId dan movieId memastikan bahwa satu pengguna hanya memberikan satu rating untuk satu film tertentu. Tingkat kelangkaan (*sparsity*) pada data rating ini akan menjadi acuan dalam menguji efektivitas sistem dalam menangani masalah *Cold Start*. Secara keseluruhan, dataset yang digunakan memiliki karakteristik statistik sebagai berikut (sesuaikan angka di bawah dengan dataset yang kamu download, misal *MovieLens Small*):

- **Jumlah Pengguna (*Users*):** ± 600 pengguna.
- **Jumlah Film (*Items*):** ± 9.000 judul film.
- **Jumlah Rating:** ± 100.000 data rating.
- **Kepadatan Matriks (*Sparsity*):** Data ini memiliki tingkat sparsity yang tinggi, yang merepresentasikan kondisi nyata pada sistem rekomendasi di mana pengguna hanya memberikan rating pada sebagian kecil dari total film yang tersedia.

userId	movieId	rating	timestamp
1	1	4.0	964982703
1	3	4.0	964981247
1	6	4.0	964982224
1	47	5.0	964983815
1	50	5.0	964982931
2	1	3.5	1445714835
2	2	4.0	1445714838
2	10	4.5	1445715029
2	17	3.0	1445715228
2	20	3.5	1445715340
3	1	2.5	1306463595
3	15	4.0	1306463600
3	16	4.5	1306463625
3	19	2.0	1306463700
4	2	3.0	964622222
4	6	4.5	964622345
4	10	5.0	964622456
4	12	1.5	964622567
5	1	4.0	847434962
5	2	3.0	847435337

Gambar 5 Dataset Rating

3.3. Data Preprocessing

Pada tahap ini, data mentah yang telah dikumpulkan akan diolah agar siap digunakan oleh model rekomendasi. Mengingat domain penelitian adalah film, proses ini mencakup pengolahan data numerik (rating) dan data tekstual (genre/sinopsis).

1. **Pembersihan Data *(Data Cleaning)*:**
    - Menghapus entri data yang duplikat atau memiliki nilai *null* (kosong) yang signifikan.
    - Memfilter pengguna atau film yang memiliki interaksi terlalu sedikit (misalnya, menghapus film yang belum pernah dirating

sama sekali) untuk menjaga kualitas data latih, namun tetap mempertahankan skenario *cold start* pada data uji.

2. **Transformasi Data Tekstual (Untuk Content-Based):**
    - Melakukan ekstraksi fitur pada atribut film seperti *Genre*, *Sinopsis*, atau *Tag*.
    - Menggunakan metode **TF-IDF (Term Frequency-Inverse Document Frequency)** atau **One-Hot Encoding** untuk mengubah data teks (misalnya genre "Action|Sci-Fi") menjadi vektor numerik agar dapat dihitung tingkat kemiripannya.
3. **Pembentukan Matriks User-Item:**
    - Membuat *Sparse Matrix* yang memetakan baris sebagai *User* dan kolom sebagai *Movie* (atau sebaliknya), dengan nilai sel berupa *rating*. Matriks ini akan menjadi input utama untuk algoritma *Collaborative Filtering*.
4. **Pembagian Data *(Data Splitting)*:**
    - Membagi dataset menjadi dua bagian: *Training Set* (Latih) dan *Test Set* (Uji).
    - Rasio pembagian yang umum digunakan adalah 80:20 atau 70:30.
    - **Catatan Khusus Cold Start:** Untuk menguji skenario *Cold Start*, pada data uji akan disimulasikan pengguna baru yang tidak memiliki riwayat rating sama sekali atau hanya memiliki sedikit rating (misal < 5 rating).

3.4. Perancangan Sistem dan Model

Komponen Content-Based Filtering (CBF) berperan dalam menganalisis karakteristik setiap film berdasarkan profil item, seperti genre maupun atribut lainnya yang telah melalui tahap ekstraksi fitur sebelumnya. Pada komponen ini, algoritma Cosine Similarity digunakan untuk menghitung tingkat kemiripan antar film melalui perbandingan vektor fitur. Pendekatan ini sangat efektif digunakan pada kondisi cold start, karena sistem tidak memerlukan riwayat rating dari pengguna lain dan dapat

langsung memberikan rekomendasi awal berdasarkan preferensi konten. Sementara itu, komponen Collaborative Filtering (CF) bekerja dengan memanfaatkan pola interaksi pengguna terhadap film. CF dapat menggunakan pendekatan memory-based seperti K-Nearest Neighbors (KNN) atau model-based seperti Singular Value Decomposition (SVD) yang termasuk dalam Matrix Factorization. Dengan menganalisis kemiripan antar pengguna atau antar item berdasarkan rating, CF mampu menghasilkan rekomendasi yang lebih akurat serta memberikan variasi konten yang lebih luas ketika pengguna telah memiliki riwayat interaksi yang cukup.

Sistem ini mengadopsi mekanisme hybrid sebagai penghubung kedua komponen tersebut. Metode yang digunakan berupa pendekatan pembobotan (weighted hybrid) atau switching hybrid untuk menentukan kontribusi masing-masing algoritma. Pada tahap awal ketika pengguna belum memiliki rating (cold start), sistem akan memberikan bobot penuh terhadap hasil rekomendasi CBF. Namun seiring bertambahnya interaksi pengguna, bobot terhadap hasil CF akan meningkat secara bertahap. Hubungan ini dapat dinyatakan melalui persamaan:

$$P_{hybrid} = \alpha \cdot P_{CBF} + (1 - \alpha) \cdot P_{CF}$$

di mana α merupakan parameter bobot yang bersifat dinamis menyesuaikan ketersediaan data interaksi pengguna.

3.5. Skenario Pengujian dan Evaluasi

Evaluasi sistem dilakukan untuk mengukur tingkat keberhasilan dalam mengatasi permasalahan *Cold Start* pada pengguna baru. Kinerja model dinilai menggunakan dua metrik utama, yaitu Mean Absolute Error (MAE) dan Root Mean Square Error (RMSE). MAE mengukur rata-rata selisih absolut antara rating prediksi dan rating sebenarnya, sedangkan

RMSE menghitung akar dari rata-rata kuadrat error, di mana nilai yang lebih kecil menunjukkan akurasi prediksi yang lebih baik. Perhitungan RMSE dinyatakan melalui persamaan:

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{y_i} - \boldsymbol{\hat{y}_i})^2}$$

Pengujian dilakukan dalam dua skenario berbeda. Pertama, skenario normal yang menilai performa sistem pada pengguna yang memiliki riwayat rating lengkap. Kedua, skenario *Cold Start* pengguna yang dilakukan dengan cara mengondisikan data seolah-olah pengguna baru (misalnya dengan menghapus atau menyisakan sangat sedikit riwayat rating). Melalui skenario ini, performa metode tunggal berbasis Collaborative Filtering kemudian dibandingkan dengan metode hybrid untuk melihat peningkatan akurasi yang diperoleh pada kondisi minim data pengguna.

3.6. Lingkungan Pengembangan

Proses implementasi sistem dilakukan pada perangkat keras berupa laptop/PC dengan spesifikasi yang akan dicantumkan pada bagian laporan akhir (meliputi kapasitas RAM, prosesor, serta GPU apabila digunakan). Seluruh pengembangan dilakukan menggunakan bahasa pemrograman Python dengan dukungan beberapa pustaka seperti Pandas untuk pengelolaan data, Scikit-learn untuk algoritma dan evaluasi, serta Surprise sebagai *library* khusus sistem rekomendasi berbasis Collaborative Filtering. Lingkungan pengembangan dijalankan melalui Jupyter Notebook atau Google Colab sebagai media eksekusi dan eksperimen kode.

DAFTAR PUSTAKA

[1] S. G. Patro, B. K. Mishra, S. K. Panda, and R. Kumar, "Hybrid recommender system for cold start problem using bi-clustering and information gain," *Multimedia Tools Appl.*, vol. 79, no. 11, pp. 6967–6990, 2020, doi: 10.1007/s11042-019-08463-5.

[2] S. Natarajan, S. Vairavasundaram, S. Natarajan, and A. H. Gandomi, "Resolving data sparsity and cold start problem in collaborative filtering recommender system using linked open data," *Expert Syst. Appl.*, vol. 149, p. 113248, Jul. 2020, doi: 10.1016/j.eswa.2020.113248.

[3] M. F. Al-Jubouri and H. T. S. AL-Rikabi, "The hybrid recommendation system for movies based on content-based and collaborative filtering," *Period. Eng. Nat. Sci. (PEN)*, vol. 8, no. 4, pp. 2172–2184, 2020.

[4] A. S. Girsang, B. Al Faruq, H. R. Herlian, and S. Simbolon, "Collaborative Recommendation System in Users of Movielens Dataset," *J. Phys. Conf. Ser.*, vol. 1566, p. 012057, Jun. 2020, doi: 10.1088/1742-6596/1566/1/012057.

[5] S. Saaidin and M. Kassim, "Recommender system: rating predictions of steam games based on genre and topic modelling," *2020 IEEE Int. Conf. Autom. Control Intell. Syst. (I2CACIS)*, IEEE, pp. 212–218, 2020, doi: 10.1109/I2CACIS49202.2020.9140194.

[6] N. Kannikaklang, S. Wongthanavasu, and W. Thamviset, "A Hybrid Recommender System for Improving Rating Prediction of Movie Recommendation," in *Proc. 19th Int. Joint Conf. Computer Sci. and Softw. Eng. (JCSSE)*, 2022, pp. 1–6.

[7] Y. Wang, "Movie Recommendation System Based on SVD Collaborative Filtering," in *Proc. 2nd Int. Conf. Artificial Intelligence, Big Data and Algorithms (CAIBDA)*, 2022.

[8] H. Yuan and A. A. Hernandez, "User Cold Start Problem in Recommendation Systems: A Systematic Review," *IEEE Access*, vol. 11, pp. 102977-103001, 2023.

[9] L. Xu, Z. Guan, and Y. Wu, “Enhancing movie recommendation systems with hybrid collaborative filtering, content-based filtering, and singular value decomposition,” in *Proceedings of the 2nd International Conference on Machine Learning and Automation (CONF-MLA)*, Adana, Turkey, 2025, doi: 10.4108/eai.21-11-2024.2354625.

[10] M. Kolli, S. S. S. N. V. S. G. K. Sastry, and V. K. Gunjan, "Addressing the cold start challenge through the implementation of content-based filtering and hybrid filtering for movie recommendation," in *2024 15th International Conference on Computing Communication and Networking Technologies (ICCCNT)*, 2024.

[11] J. M. A. Saputra, L. M. Huizen, and D. B. Arianto, “Sistem rekomendasi film pada platform streaming menggunakan metode content-based filtering,” *J. Transformatika*, vol. 22, no. 1, pp. 10–21, 2024.

[12] D. P. Rini, S. M. Samsuddin, and F. S. Utomo, “SVD-GoRank: Recommender System Algorithm Using SVD and Gower’s Ranking,” *IEEE Access*, vol. 13, pp. 1245–1260, 2025.

[13] J. M. Zawia, et al., “Comprehensive Review of Meta-Learning Methods for Cold-Start Issue in Recommendation Systems,” *IEEE Access*, vol. 13, pp. 2045–2062, 2025.